

缺血性中风的密集多路径 U-Net

多幅图像中的病变分割

方式

何塞·多尔兹¹, 伊斯梅尔·本·艾德¹, 克里斯蒂安·德罗西耶¹

影像、视觉与人工智能实验室
加拿大蒙特利尔高等技术学院
jose.dolz@livia.etsmtl.ca

描绘缺血性中风病变中的梗塞组织对于确定
对这种危及生命的疾病的损害范围和最佳治疗方法。然而,由于化学中风的位置和形状的高度
可变性,这个问题仍然具有挑战性。最近,全卷积神经网络

(CNN),特别是基于 U-Net [27] 的那些,已经提高了这项任务的性能 [7]。在这项工作中,
我们提出了一种新颖的架构,以三种重要方式改进了基于标准 U-Net 的方法。首先,而不是

在输入端结合可用的图像模态,对它们中的每一个模态进行处理
以不同的方式更好地利用他们的独特信息。此外,网络是密集连接的(即每一层都连接到所
有后续层),
在每条路径内和不同路径之间,类似于 HyperDenseNet [11]。
这使我们的模型可以自由地学习模态应该采用的规模
进行处理和组合。最后,受 Inception 架构 [32] 的启发,
我们通过使用两个扩展初始模块来改进标准 U-Net 模块
具有不同尺度扩张卷积的卷积块。这有助于处理病变大小的可变性。我们将 93 个笔画数据集
拆分为训练
和分别包含 83 个和 9 个示例的验证集。我们的网络是
在具有 16 GB RAM 的 NVidia TITAN XP GPU 上进行训练,使用 ADAM 作为优化器,在
200 个 epoch 期间学习率为 1×10^{-5} 。培训开始了
5 小时,整个卷的分割需要 0.2 到 2 秒,因为
平均。比较我们的方法在测试集上的表现
到几个基线,以展示我们架构的有效性,以及
到采用分解扩张卷积的最先进的架构,即
ERFNet [26]。

1 简介

中风是全球死亡的主要原因之一,估计有 600 万人
每年的案例 [19,28]。这也是导致长期残疾的主要原因,导致
运动控制降低、感觉或情绪障碍、站立语言困难和记忆力减退。脑缺血,它来自

大脑中的血管阻塞,约占所有血管的 80%
中风病例 [31,13]。基于计算机断层扫描的脑成像方法

(CT) 和磁共振成像 (MRI) 通常用于评估中风患者 [34]。早期缺血性卒中在 CT 中表现为低密度区域,因此很难用这种方式定位。MRI 序列,例如 T1 加权、T2 加权、流体衰减反转恢复 (FLAIR) 和弥散加权成像 (DWI),提供比 CT 更清晰的脑组织图像,是评估脑组织位置和演变的首选方式缺血性卒中病变 [3,2,18]。

中风病变的精确描绘对于确定组织损伤的范围及其对认知功能的影响至关重要。然而,在多模态 MRI 数据中手动分割病灶既费时又容易出现观察者间和观察者内的差异。因此,开发自动分割方法有助于拥有更有效和可靠的工具来量化中风病变随着时间的推移[24]。多年来,已经提出了各种半自动化和自动化技术来分割病变 [25,21]。最近,深度卷积神经网络 (CNN) 在这项任务中表现出高性能,在基准数据集上优于标准分割方法 [20,35,14,4,17]。

基于 CNN 的多模态图像分割通常通过早期融合策略来解决,其中多个模态从低级特征的原始输入空间合并 [39,22,16,17,10,33]。该策略假定不同模式之间存在简单的关系(例如,线性),这可能与现实不符[30]。例如,[39] 中的方法从 T1、T2 和 FA 图像中学习互补信息,但是由于图像采集过程的不同,这些图像之间的关系可能更复杂。为了更好地解释这种复杂性,Nie 等人。[23] 提出了一种后期融合方法,其中每个模态都由一个独立的 CNN 处理,其输出在深层融合。作者展示了这种策略在婴儿大脑分割任务上的表现优于早期融合。

最近,Aigün 等人。探索了组合多种模式的不同方法[1]。在这项工作中,所有模态都被视为不同 CNN 的单独输入,然后在“早期”、“中间”或“晚期”点融合。尽管发现“后期”融合提供了更好的性能,如 [23] 中所示,但该方法依赖于单层融合来模拟所有模态之间的关系。然而,正如几项工作 [30] 所证明的,不同模式之间的关系可能非常复杂,并且它们不能轻易地由单层建模。为了解释多模态数据建模中的非线性,我们最近提出了一种 CNN,它不仅在同一路径内的层对之间,而且在跨不同路径的层之间也包含密集连接 [9,11]。这种被称为 HyperDenseNet 的架构在使用多个 MRI 数据进行婴儿和成人脑组织分割的背景下获得了非常有竞争力的性能。

尽管现有方法具有显著的性能,但不同抽象级别的多模态数据的组合尚未完全用于缺血性卒中病变的分割。在本文中,我们采用 [9,11] 中提出的策略并提出了一种多路径架构,其中每种模式




图 1. 提出的架构多路径密集 UNet。虚线表示此 UNet 扩展版本中采用的一些密集连接模式。

被用作一个流的输入,并且在相同和不同路径中的层之间使用密集连接。此外,我们还扩展了 InceptionNet [32] 的标准卷积模块,包括两个额外的扩张卷积块,这可能有助于学习更大的上下文。2018 年缺血性中风病变分割 (ISLES) 挑战赛中 103 种缺血性中风病变多模式扫描的实验表明,我们的模型优于基于早期和晚期融合的架构,以及最先进的分割网络。

2 方法论

所提出的模型建立在 UNet 架构 [27] 之上,该架构在各种医学分割任务 [8,12] 中表现出出色的性能。该网络由收缩和扩展路径组成,前者将图像分解为一组高级特征,后者使用这些特征构建逐像素分割掩码。使用跳跃连接,来自早期层的输出连接到后续层的输入,目的是传输可能在编码路径中丢失的信息。

2.1 提出的多模态 UNet

解开输入数据。图 1 描绘了我们提出的用于在多种图像模式中进行缺血性卒中病变分割的网络。与大多数类似 UNet 的架构不同,编码路径被分成 N 个流,作为每个图像模式的输入。在分离的流中处理每个模式的主要目的是解开原本会从早期阶段融合的信息,并具有之前介绍的缺点,即限制捕获模态之间的复杂关系。

超密集连接。受最近在医学图像分割工作中密集和超密集连接网络的成功启发 [37,5,9,11],我们建议扩展 UNet 以适应




图 2. 多模式场景中提议的密集连接部分的详细版本。为简单起见,在此示例中考虑了两种图像模式。

相同并且在多个路径之间。除了更好地建模不同模式之间的关系外,采用密集连接还带来了以下三个好处 [15]。首先,所有层之间的直接连接有助于改善整个网络的信息流和梯度,缓解梯度消失的问题。其次,架构中所有特征图的短路路径引入了隐式的深度监督。第三,密集连接具有正则化效果,可以降低在较小训练集的任务上过度拟合的风险。

在标准 CNN 中, l 的输出 x_l 层,记为 x_l , 通常通过映射 H_l 从前一层 x_{l-1} 的输出中获得:

$$x_l = H_l x_{l-1}. \quad (1)$$

其中 H_l 通常集成一个卷积层,然后是一个非线性激活。在密集连接的神经网络中,所有特征输出都以前馈方式连接,

$$x_l = H_l [x_{l-1}, x_{l-2}, \dots, x_0], \quad (2)$$

在哪里 $[\dots]$ 表示连接操作。

与在 HyperDenseNet [9,11] 中一样,不同流中层的输出也相互关联。这种连通性产生了比多模态上下文中的早期或晚期融合策略更强大的特征表示,因为网络学习了模态内部和中间模态之间的复杂关系。

所有的抽象层次。考虑只有两种模态的情况,设 x_2 和 x_1 分别位于流 1 和 2 中的层。在层中的流 s 可以定义一般说来, l 的输出如下:

$$x_l^s = H_s \left[x_{l-1}^1, x_{l-1}^2, \dots, x_{l-1}^s, \dots, x_0^1, x_0^2, \dots, x_0^s \right]. \quad (3)$$

受 [6,38,40] 中最近发现的启发,其中 CNN 中的混洗和交错特征图元素提高了效率和性能,同时作为一个强大的正则化器,我们为每个分支和层以不同的顺序连接特征图:

$$x_l^s = H_s \pi_l^s \left([x_{l-1}^1, x_{l-1}^2, \dots, x_{l-1}^s, \dots, x_0^1, x_0^2, \dots, x_0^s] \right), \quad (4)$$

在两种图 是一个置换作为输入给出的特征图的函数。因此，像模式的情况下，使用 πl ，我们有：

$$\begin{aligned} 1 \times l_1 &= H1 \quad l_1 \quad [X^1 \quad 2 \ 1 \ 2 \ 1 \ 2 \ \text{xxxxx} \ l-1, \ l-1, \ l-2, \ l-2, \ \dots, \ 0, \ 0, \ 2] \\ 2 \times l &= H2 \quad [X \quad 1 \ 2 \ 1 \ 2 \ 1 \ \text{xxxxx} \ l-1, \ l-1, \ l-2, \ l-2, \ \dots, \ 0, \ 0] \end{aligned}$$

图 2 描述了两图像模式的超密集连接的详细示例。

2.2 扩展Inception模块

给定图像中的显着区域的大小变化可能非常大。例如，在缺血性中风病变分割中，病变占据的区域从一张图像到另一张图像变化很大。因此，选择合适的内核大小并非易事。虽然较小的内核更适合本地信息，但较大的内核更适合捕获全球分布的信息。

InceptionNet [32] 通过包含在同一级别上运行的具有多个内核大小的卷积来利用这一原理。此外，在版本 2 和 3 中， $n \times n$ 形状的卷积被分解为 $1 \times n$ 和 $n \times 1$ 卷积的组合，这已被证明更有效。例如，一个 3×3 的卷积相当于一个 1×3 后跟一个 3×1 的卷积，发现要便宜 33%。

我们还扩展了 InceptionNet 的卷积模块以促进多上下文的学习。特别是，我们包括了两个额外的卷积块，具有不同的膨胀率，这有助于模块从多个感受野中学习，并增加原始初始模块的上下文。由于在捕获全局上下文时，扩张卷积被证明是最大池的更好替代方案 [36]，因此我们在提议的模块中删除了后一种操作。我们扩展的初始模块如图 3 所示。

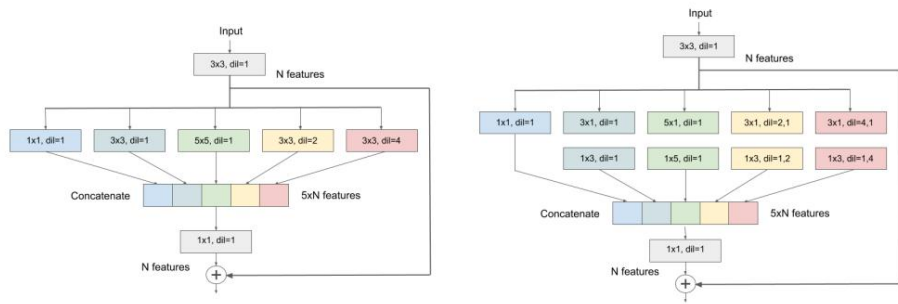


图 3. 提出的扩展初始模块。左边的模块采用标准卷积，而右边的模块采用不对称卷积的思想[32]。

3 材料

3.1 数据集

由 ISLES 组织者提供的训练数据集由 103 个缺血性中风病变多模式扫描组成。我们将 94 个笔画数据集拆分为训练集和验证集,分别包含 83 个和 11 个示例。每次扫描包含:扩散图 (DWI) 和灌注图 (CBF、MTT、CBV、Tmax 和 CTP 源数据)。此外,手动地面实况分割仅针对训练样本提供。有关数据集的详细信息可以在 ISLES 网站¹ 中找到。

3.2 评价指标

骰子相似系数 (DSC)。我们首先使用 Dice 相似系数 (DSC) 来评估性能,该系数根据它们的重叠来比较体积。设 V_{ref} 和 V_{auto} 分别是给定组织类别的参考和自动分割,对于给定的受试者,该受试者的 DSC 定义为:

$$DSC(V_{ref}, V_{auto}) = \frac{2 |V_{ref} \cap V_{auto}|}{|V_{ref}| + |V_{auto}|} \quad (5)$$

修正豪斯多夫距离 (MHD)。第二个指标衡量分割边界的准确性。让 P_{ref} 和 P_{auto} 分别表示参考和自动分割边界内的体素集。

MHD 由下式给出

$$MHD(P_{ref}, P_{auto}) = \max_{q \in P_{ref}} \min_{p \in P_{auto}} d(q, p), \quad (6)$$

其中 $d(q, P)$ 是点到集合的距离,定义为: $d(q, P) = \min_{p \in P} \|q - p\|$, 其中 $\| \cdot \|$ 表示欧几里得距离。在 MHD 中,第95个百分位用于估计最大距离值。低 MHD 值表示高边界相似性。

体积相似度 (VS)。体积相似度 (VS) 忽略了预测和参考分割之间的重叠,只是将预测体积的大小与参考的大小进行比较:

$$VS(V_{ref}, V_{auto}) = 1 - \frac{|V_{ref}| - |V_{auto}|}{|V_{ref}| + |V_{auto}|} \quad (7)$$

其中 VS 等于 1 反映了预测的分割与参考体积的大小相同。

¹ <http://www.isles-challenge.org>

3.3 实施细节

基线。为了证明深度神经网络中超密集连接的有效性,我们将提出的架构与具有早期和晚期融合策略的相同网络进行比较。对于早期融合,所有 MRI 图像模态都被合并到一个输入中,该输入通过一个独特的路径进行处理,就像当前的许多工作一样。另一方面,每个图像模态被视为一个独立的信号,并在后期融合策略中由单独的分支处理,其中特征在更高级别融合。晚期融合架构的细节在表 1 中描述。在两种情况下,即早期和晚期融合,都使用了图 3 中描绘的左侧模块。此外,来自跳过连接的特征图在被馈送到解码路径的卷积模块之前被求和,而不是像标准 UNet 中那样将它们连接起来。

建议的网络。所提出的网络类似于具有后期融合策略的架构。然而,如第 2.1 节所述,来自前一层和不同路径的特征图被连接起来并馈送到后续层。最终架构的详细信息在表 1 最右侧的列中进行了报告。所提出网络的第一个版本使用与两个基线相同的卷积模块。然而,第二个版本采用了非对称卷积(图 3)。

表 1. 后期融合架构的层处理和提出的超密集连接 UNet。

| | | 后期融合 | | 超密集连接 | |
|----------|-----------|----------------------------|----------------------------|--------------------------------------|----------------------------|
| | 姓名 | 专长图 (输入) | 专长地图 (输入) (输出) | 专长地图 | 专长图 (输出) |
| 编码 小路 | 卷积层 | $1 \times 256 \times 256$ | $32 \times 256 \times 256$ | $1 \times 256 \times 256$ | $32 \times 256 \times 256$ |
| | 最大池化 1 | $32 \times 256 \times 256$ | $32 \times 128 \times 128$ | $32 \times 256 \times 256$ | $32 \times 128 \times 128$ |
| | 第二层 | $32 \times 128 \times 128$ | $64 \times 128 \times 128$ | $128 \times 128 \times 128$ | $64 \times 128 \times 128$ |
| | 最大池化 2 | $64 \times 128 \times 128$ | $64 \times 64 \times 64$ | $128 \times 128 \times 64 \times 64$ | (每种模态) |
| | 第三层 | $64 \times 64 \times 64$ | $128 \times 64 \times 64$ | $384 \times 64 \times 64$ | $128 \times 64 \times 64$ |
| | 最大池化 3 | $128 \times 64 \times 64$ | $128 \times 32 \times 32$ | $128 \times 64 \times 64$ | $128 \times 32 \times 32$ |
| | 第四层 | $128 \times 32 \times 32$ | $256 \times 32 \times 32$ | $896 \times 32 \times 32$ | $256 \times 32 \times 32$ |
| 解码 小路 | 最大池化 4 | $256 \times 32 \times 32$ | $256 \times 16 \times 16$ | $256 \times 32 \times 32$ | $256 \times 16 \times 16$ |
| | 桥梁 | $1024 \times 16 \times 16$ | $512 \times 16 \times 16$ | $1920 \times 16 \times 16$ | $512 \times 16 \times 16$ |
| | 上采样 1 | $512 \times 16 \times 16$ | $256 \times 32 \times 32$ | $512 \times 16 \times 16$ | $256 \times 32 \times 32$ |
| | 第 5 层 | | $256 \times 32 \times 32$ | $256 \times 32 \times 32$ | $256 \times 32 \times 32$ |
| | 上采样 2 | $256 \times 32 \times 32$ | $128 \times 64 \times 64$ | $256 \times 32 \times 32$ | $128 \times 64 \times 64$ |
| | 第 6 层 | | $128 \times 64 \times 64$ | $128 \times 64 \times 64$ | $128 \times 64 \times 64$ |
| | 上采样 3 | $128 \times 64 \times 64$ | $64 \times 128 \times 128$ | $64 \times 64 \times 64$ | 128×128 |
| | 7层 | $64 \times 128 \times 128$ | $64 \times 128 \times 64$ | $128 \times 64 \times 128$ | 128×128 |
| | 上采样 4 | $64 \times 128 \times 128$ | $32 \times 256 \times 256$ | $64 \times 128 \times 32 \times 256$ | 256 |
| | 第8层 | $32 \times 256 \times 256$ | $32 \times 256 \times 256$ | $32 \times 256 \times 256$ | $32 \times 256 \times 256$ |
| | Softmax 层 | $32 \times 256 \times 256$ | $2 \times 256 \times 256$ | $32 \times 256 \times 256$ | $2 \times 256 \times 256$ |

训练。网络参数通过 Adam 优化, β_1 和 β_2 分别等于 0.9 和 0.99,训练在 200 个时期内运行。学习率最初设置为 1×10^{-4} ,并在 100 个 epoch 后降低。批量大小等于 4。为了公平比较,使用了相同的超参数

跨越所有架构。建议的架构在火炬。实验在 NVidia TITAN XP GPU 上进行,具有 16 GB 内存。虽然训练大约需要 5 个小时,但在单个 2D 图像上进行推理平均在 0.1 秒内完成。没有使用数据增强。图片在 0 和 1 之间进行归一化,没有其他预处理或后处理步骤被使用了。作为架构的输入,我们使用了以下四个图像所有情况下的模式:CBV、CTP、DWI 和 MTT。

4 个结果

表 2 报告了我们根据平均 DSC、MHD 和 VS 值及其标准偏差研究的不同网络获得的结果。首先,我们将不同的多模态融合策略与

在这项工作中使用的基线 UNet。我们可以观察到,在更高级别融合学习特征在所有指标上都比早期融合提供更好的结果策略。此外,如果在后期融合中采用超密集连接架构,即将来自不同图像的卷积层相互连接模态,分割性能显着提高,特别是在 DSC 和 VS 方面。具体来说,虽然提议的网络表现出色在 DSC 和 VS 中,晚期融合架构降低了近 5%,平均 MHD 减少了近 1 毫米,平均 MHD 为 18.88 毫米。在另一手,替换建议模块的标准卷积 (图 3,左) 通过不对称卷积 (图 3,右),再次提升性能在提议的超密集 UNet 上。在这种情况下,平均 DSC 和 MHD 是所有架构中最好的,平均值分别为 0.635% 和 18.64 毫米,分别。

表 2. 平均 DSC、MHD 和 VS 值及其相应的标准偏差,通过独立验证组的评估方法获得。

| 验证 | | |
|-------------|---|-----------------------------|
| 建筑学 | DSC (%) MHD (毫米) | VS (%) |
| 早期融合 | 0.497 ± 0.263 21.30 ± 13.25 0.654 ± 0.265 | |
| 后期融合 | 0.571 ± 0.221 19.72 ± 12.29 0.718 ± 0.235 | |
| 建议 | 0.622 ± 0.233 18.88 ± 14.87 0.764 ± 0.247 | |
| 建议 (非对称转换) | 0.635 ± 0.186 18.64 ± 14.26 0.796 ± 0.162 | |
| ERFNet [26] | 0.540 ± 0.258 | 21.73 ± 11.46 0.823 ± 0.119 |

然后,我们还将提出的网络获得的结果与另一个包含分解卷积模块的最先进的网络,即,ERFNet。即使它的性能早于基线融合,结果与提议的网络获得的结果相去甚远,除了对于体积相似度,ERFNet 和提议的网络都具有不对称卷积获得类似的性能。

在图 4 中评估了所提出架构的定性评估,其中地面实况和自动 CNN 轮廓在 MTT 图像上可视化。我们

可以首先观察到,通过采用在更高级别合并学习特征的策略,与早期融合不同,缺血性中风病变的区域通常被更好地覆盖。此外,通过让架构自由地学习不同模态应该组合的抽象级别,分割结果在视觉上得到了改进,这与表 2 中报告的结果一致。




图 4. 验证集上两个主题的视觉结果。黄色区域代表基本事实,紫色轮廓描绘了每个架构的自动轮廓。

5 讨论

在这项工作中,我们扩展了著名的 UNet 以利用多模态数据中的信息。特别是,在最近用于医学图像分割的多模态学习[9,11]之后,我们处理了编码路径上不同流中的每个图像模态,并密集连接了所有流中的所有卷积层。因此,每个卷积层接收来自同一流中所有先前层的特征映射作为输入,即相同的模态,但也接收来自每个不同流中先前层的学习特征。这样,网络在网络的任何抽象层次上都可以自由地学习任何模式,这似乎提高了它的表示学习能力。

在这项工作中获得的结果表明,与更简单的融合策略相比,更好的多模态信息建模策略可以提高性能。这些结果与医学领域多模态图像分割的最新研究一致[23,9,11]。例如,在[23]中,提出了一种后期融合策略来结合高级特征以更好地

捕捉不同模式之间的复杂关系。他们为每种模态使用了一个独立的卷积网络,并将不同网络的输出融合到更高级别的层中,在婴儿大脑分割的上下文中显示出比早期融合更好的性能。最近,我们证明了超密集连接可以在多模态图像婴儿和成人脑分割的背景下增强深度 CNN 的表示能力,超过了几种特征融合策略的性能 [9,11]。

这项工作的一个限制是卷被视为一堆 2D 幻灯片,其中每张幻灯片都是独立处理的。因此,3D 上下文被丢弃,这可能提高了分割性能,如最近使用 3D 卷积的作品所示。授予 2D 卷积特权的原因之一是 ISLES 数据集上的某些卷包含有限数量的幻灯片,即在许多情况下为 2 和 4 个幻灯片。未来探索的一种策略可能是使用长短期记忆 (LSTM) 网络通过三维传播从 2D CNN 提取的空间信息。

致谢 这项工作得到了加拿大国家科学和工程研究委员会 (NSERC)、发现资助计划以及 ETS 医学成像人工智能研究主席的支持。

参考

1. M. Aygün, Y. H. Sahin 和 G. Unal。用于脑肿瘤分割的多模态卷积神经网络。 arXiv 预印本 arXiv:1809.06191, 2018。
2. P. Barber, M. Hill, M. Eliasziw, A. Demchuk, J. Pexman, M. Hudon, A. Tomanek, R. Frayne 和 A. Buchan。急性缺血性中风的大脑成像:计算机断层扫描和磁共振扩散加权成像的比较。神经病学、神经外科和精神病学杂志,76 (11):1528-1533,2005。
3. JA Chalela, CS Kidwell, LM Nentwich, M. Luby, JA Butman, AM Demchuk, MD Hill, N. Patronas, L. Latour 和 S. Warach。磁共振成像和计算机断层扫描在疑似急性卒中患者紧急评估中的前瞻性比较。柳叶刀,369 (9558):293-298,2007。
4. L. Chen, P. Bentley 和 D. Rueckert。使用卷积神经网络在 DWI 中全自动急性缺血性病变分割。神经影像:临床,15:633-643,2017。
5. L. Chen, Y. Wu, AM DSouza, AZ Abidin, A. Wismüller 和 C. Xu。使用密集连接的 3D CNN 进行 MRI 肿瘤分割。在 2018 年医学影像:图像处理。国际光学与光子学学会,2018 年。
6. Y. Chen, H. Wang 和 Y. Long。使用 shufflenode 对卷积神经网络进行正则化。In Multimedia and Expo (ICME), 2017 年 IEEE 国际会议,第 355-360 页。IEEE,2017。
7. Y. Choi, Y. Kwon, H. Lee, BJ Kim, MC Paik 和 J.-H. 韩元。用于缺血性卒中预后的深度卷积神经网络集成。在脑损伤研讨会:神经胶质瘤、多发性硬化、中风和创伤性脑损伤,第 231-243 页。斯普林格,2016。

8. O. C. i, cek, A. Abdulkadir, S. S. Lienkamp, T. Brox 和 O. Ronneberger. 3d u-net:从稀疏注释中学习密集的体积分割。在 MICCAI, 第 424-432 页。斯普林格, 2016。
9. J. Dolz, I. Ben Ayed, J. Yuan 和 C. Desrosiers. 具有超密集连接卷积神经网络的等强度婴儿脑分割。在生物医学成像 (ISBI 2018), 2018 年 IEEE 第 15 届国际研讨会上, 第 616-620 页。IEEE, 2018。
10. J. Dolz, C. Desrosiers, L. Wang, J. Yuan, D. Shen 和 I. B. Ayed. 用于婴儿大脑 MRI 分割的深度 CNN 集合和提示性注释。arXiv 预印本 arXiv:1712.05319, 2017。
11. J. Dolz, K. Gopinath, J. Yuan, H. Lombaert, C. Desrosiers 和 I. B. Ayed. Hyperdense-net:用于多模态图像分割的超密集连接 cnn。arXiv 预印本 arXiv:1804.02967, 2018。
12. H. Dong, G. Yang, F. Liu, Y. Mo 和 Y. Guo. 使用基于 u-net 的全卷积网络自动检测和分割脑肿瘤。在 MIUA, 第 506-517 页。斯普林格, 2017。
13. V. L. Feigin, C. M. Lawes, D. A. Bennett 和 C. S. Anderson. 中风流行病学:回顾 20 世纪后期基于人群的发病率、患病率和病死率研究。《柳叶刀神经病学》, 2 (1):43-53, 2003。
14. R. Guerrero, C. Qin, O. Oktay, C. Bowles, L. Chen, R. Joules, R. Wolz, M. Valdes Hernandez, D. Dickie, J. Wardlaw 等。使用卷积神经网络的白质高信号和中风病变分割和分化。神经影像:临床, 17:918-934, 2018。
15. G. Huang, Z. Liu, L. Van Der Maaten 和 K. Q. Weinberger. 紧密相连卷积网络。在 CVPR, 第 1 卷, 第 3 页, 2017 年。
16. K. Kamnitsas, L. Chen, C. Ledig, D. Rueckert 和 B. Glocker. 用于脑 MRI 病灶分割的多尺度 3D 卷积神经网络。缺血性中风病变分割, 2015 年 13 月。
17. K. Kamnitsas, C. Ledig, V. F. Newcombe, J. P. Simpson, A. D. Kane, D. K. Menon, D. Rueckert 和 B. Glocker. 具有完全连接 CRF 的高效多尺度 3D CNN, 用于准确的脑部病变分割。医学图像分析, 36:61-78, 2017。
18. M. G. Lansberg, G. W. Albers, C. Beaulieu 和 M. P. Marks. 弥散加权 mri 和 ct 在急性中风中的比较。神经病学, 54(8):1557-1561, 2000。
19. A. D. Lopez, C. D. Mathers, M. Ezzati, D. T. Jamison 和 C. J. Murray. 全球和区域疾病负担和风险因素, 2001 年:人口健康数据的系统分析。柳叶刀, 367 (9524):1747-1757, 2006。
20. O. Maier, B. H. Menze, J. von der Gabelntz, L. Hani, M. P. Heinrich, M. Liebrand, S. Winzeck, A. Basit, P. Bentley, L. Chen 等人。Isles 2015 - 从多光谱 MRI 进行缺血性卒中病变分割的公共评估基准。医学图像分析, 35:250-269, 2017。
21. O. Maier, C. Schroder, N. D. Forkert, T. Martinetz 和 H. Handels. 缺血性中风病变分割的分类:一项比较研究。PloS 一, 10(12):e0145118, 2015。
22. P. Moeskops, M. A. Viergever, A. M. Mendrik, L. S. de Vries, M. J. Benders 和 I. v. sgum. 使用卷积神经网络自动分割 MR 大脑图像。IEEE 医学影像汇刊, 35(5):1252-1261, 2016。
23. D. Nie, L. Wang, Y. Gao 和 D. Sken. 用于多模态等强度婴儿大脑图像分割的全卷积网络。在第 13 届生物医学成像国际研讨会 (ISBI), 2016 年, 第 1342-1345 页。IEEE, 2016。

24. G. Praveen, A. Agrawal, P. Sundaram 和 S. Sardesai. 使用堆叠稀疏自动编码器进行缺血性中风病变分段。生物学和医学中的计算机, 2018 年。
25. I. Rekik, S. Allassonni`ere, TK Carpenter 和 JM Wardlaw. MR/CT 成像急性-亚急性缺血性卒中病变中的医学图像分析方法: 动态演化模拟模型的分段、预测和洞察。批判性的评价。神经影像: 临床, 1 (1): 164-178, 2012。
26. E. Romera, JM Alvarez, LM Bergasa 和 R. Arroyo. Erfnet: 用于实时语义分割的高效残差分解卷积网络。IEEE 智能交通系统汇刊, 19(1): 263-272, 2018。
27. O. Ronneberger, P. Fischer 和 T. Brox. U-net: 用于生物医学图像分割的卷积网络。在 MICCAI, 第 234-241 页。斯普林格, 2015。
28. S. Seshadri 和 PA Wolf. 中风和痴呆的终生风险: 当前的概念和弗雷明汉研究的估计。柳叶刀神经病学, 6(12): 1106-1114, 2007。
29. K. Sirinukunwattana, JP Pluim, H. Chen, X. Qi, P.-A. 恒, 郭, LY 王, BJ Matuszewski, E. Bruni, U. Sanchez, 等。结肠组织学图像中的腺体分割: glas 挑战赛。医学图像分析, 35: 489-502, 2017。
30. N. Srivastava 和 R. Salakhutdinov. 使用深度 Boltzmann 机器进行多模态学习。机器学习研究杂志, 15: 2949-2980, 2014。
31. C. Sudlow 和 C. Warlow. 中风发病率及其病理类型的可比性研究: 国际合作的结果。中风, 28 (3): 491-499, 1997。
32. C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens 和 Z. Wojna. 重新思考计算机视觉的初始架构。在 CVPR, 第 2818-2826 页, 2016 年。
33. S. Valverde, M. Cabezas, E. Roura, S. Gonz´alez-Vill`a, D. Pareto, JC Vilanova, L. Rami´o-Torrent`a, A. Rovira, A. Oliver 和 X. Llad`o. 使用级联 3D 卷积神经网络方法改进自动多发性硬化病灶分割。神经影像学, 155: 159-168, 2017。
34. HB Van der Worp 和 J. van Gijn. 急性缺血性中风。新英格兰医学杂志, 357 (6): 572-579, 2007。
35. S. Winzeck, A. Hakim, R. McKinley, JA Pinto, V. Alves, C. Silva, M. Pisov, E. Krivov, M. Belyaev, M. Monteiro 等。Isles 2016 和 2017 年基于多光谱 mri 的基准缺血性卒中病变结果预测。神经病学前沿, 2018 年 9 月。
36. F. Yu 和 V. Koltun. 通过扩张卷积进行多尺度上下文聚合。arXiv 预印本 arXiv:1511.07122, 2015。
37. L. Yu, J.-Z. Cheng, Q. Dou, X. Yang, H. Chen, J. Qin 和 P.-A. 恒. 具有密集连接的体积卷积网络的自动 3D 心血管 MR 分割。在 MICCAI, 第 287-295 页。斯普林格, 2017。
38. T. 张, G.-J. 齐, B. 肖和 J. 王. 交错组卷积。在 CVPR, 第 4373-4382 页, 2017 年。
39. W. Zhang, R. Li, H. Deng, L. Wang, W. Lin, S. Ji 和 D. Shen. 用于多模态等强度婴儿大脑图像分割的深度卷积神经网络。神经影像学, 108: 214-224, 2015。
40. X. Zhang, X. Zhou, M. Lin 和 J. Sun. Shufflenet: 用于移动设备的极其高效的卷积神经网络。arXiv 预印本 arXiv:1707.01083, 2017。